# INFORME FINAL DE ANÁLISIS EXPLORATORIO DE DATOS DEL CONJUNTO DE DATOS

### SarcOji

# 1. Hipótesis iniciales:

### 1.1. Motivación

El sarcasmo es una forma de comunicación sofisticada y ambigua que combina tono, contexto y contradicciones implícitas para expresar un mensaje opuesto al que aparenta. Su detección automática representa un reto significativo para los modelos de procesamiento de lenguaje natural, ya que los sistemas tradicionales tienden a basarse en señales literales o superficiales del texto, como la polaridad emocional.

El dataset SARCOJI ofrece una oportunidad valiosa para explorar este fenómeno desde una perspectiva novedosa: la relación entre el uso de emojis, las emociones expresadas en el texto y la probabilidad de que una publicación sea sarcástica. Al contener métricas de sentimiento calculadas a partir de distintas fuentes —texto, emojis, y sus respectivas polaridades según varios algoritmos— el dataset permite analizar si estas dimensiones emocionales están alineadas o en conflicto, y si dicha información puede servir como indicador del sarcasmo.

A partir de la motivación anterior y del conocimiento teórico sobre lenguaje sarcástico y análisis de sentimiento, se definieron las siguientes hipótesis de análisis:

• H1. Las publicaciones sarcásticas mostrarán una débil o nula correlación entre el sentimiento del texto y el de los emojis.

Justificación: El sarcasmo a menudo consiste en una contradicción entre lo que se dice y lo que se quiere dar a entender. Se espera, por tanto, que los emojis puedan expresar emociones diferentes o incluso opuestas a las del texto literal.

 H2. Las métricas de sentimiento convencionales (como Vader, TextBlob, SentiWordNet) no se correlacionan significativamente con la variable Sarcastic.

Justificación: Estos métodos están diseñados para detectar polaridad explícita (positiva/negativa), pero el sarcasmo no siempre se manifiesta mediante polaridad emocional clara, sino mediante ambigüedad, ironía o juego semántico.

 H3. Existen patrones internos de alta correlación entre variables derivadas de emojis, lo que sugiere que pueden usarse como un solo bloque de representación emocional. Justificación: Al tener múltiples métricas sobre los mismos emojis (por ejemplo, polaridad promedio vs. emoji más representativo), se espera una fuerte colinealidad entre estas variables.

 H4. La variable ESR (Emoji Sentiment Rating) estará más alineada con el sentimiento de los emojis que con el sentimiento textual o la presencia de sarcasmo.

Justificación: ESR es una medida basada en el consenso social sobre el significado emocional de cada emoji, por lo que se espera que refleje mejor la carga afectiva de los emojis, pero no necesariamente su uso sarcástico o irónico.

### 1.2. Hipótesis

- ¿Existe una correlación entre el sentimiento del texto y el sentimiento de los emojis? ¿Se debilita o desaparece esa correlación cuando la publicación es sarcástica?
- ¿Las publicaciones sarcásticas utilizan emojis con una mayor intensidad emocional (ya sea positiva o negativa) que las publicaciones no sarcásticas?
- ¿El sarcasmo es más frecuente en publicaciones que expresan emociones negativas, ya sea en el texto o en los emojis?
- ¿Las publicaciones sarcásticas presentan mayor disonancia emocional entre el texto y los emojis, es decir, una menor coherencia entre ambos tipos de sentimiento?

### 1.3. Plan de análisis

### 1. Inspección inicial y estructura del dataset

Comprender la composición y tipología de los datos disponibles.

### Acciones:

- a. Revisión de columnas, tipos de datos y descripción general del contenido
- b. Identificación de valores nulos, valores de control especiales (ej. −1) y posibles codificaciones no estándar.

Relación con hipótesis: todas — establece la base para el análisis posterior.

### 2. Identificación de variables numéricas no categóricas

Estudiar la distribución y escala de las métricas numéricas, en especial aquellas relacionadas con sentimiento.

### Acciones:

- a. Filtrado de columnas numéricas excluyendo categorías o binarias.
- b. Análisis de rangos dispares entre métodos de análisis de sentimiento (ej. Vader: -1 a 1 vs. SWN: -3 a +7).

### 3. Detección y tratamiento de valores inconsistentes

Identificar valores especiales (como −1) usados para codificar "falta de datos".

#### Acciones:

- a. Revisión de columnas como MaxEmojiNumOccurence o MaxEmojiPos que usan −1 para indicar ausencia.
- b. Reemplazo por valores nulos (NaN) cuando corresponda.

Relación con hipótesis: todas — garantiza validez estadística.

### 4. Análisis de correlaciones y covarianzas

Medir relaciones lineales entre variables para evaluar coherencia interna y capacidad explicativa.

### Acciones:

- Cálculo de matrices de correlación de Pearson y covarianza entre variables de sentimiento (textuales y de emojis).
- Análisis cruzado entre polaridad textual y polaridad emoji.
- Evaluación específica de la relación entre la variable Sarcastic y las métricas de sentimiento.

### Relación con hipótesis:

- H1: Discordancia entre sentimiento de texto y emojis.
- H2: Baja correlación entre sentimiento y sarcasmo.
- H3: Redundancia entre métricas de sentimiento.

### 5. Evaluación conceptual de coherencia semántica

Interpretar relaciones encontradas desde un punto de vista semántico y comunicativo.

### Acciones:

- Interpretación de correlaciones inesperadas o ausentes.
- Evaluación de hipótesis a partir del marco teórico sobre el sarcasmo como forma de contradicción semántica.
- Discusión sobre el significado contextual del uso de emojis frente al tono literal del texto.

Relación con hipótesis: H1 y H4 — significado divergente entre emociones y uso irónico.

# Fuente de datos:

### 2.1. **Fuente**:

El dataset original SarcOji se encuentra alojado en un repositorio de github de sus mismos autores.

### Responsables:

Los responsables de recolectar y compilar el dataset SarcOji [1] fueron las autoras del artículo: Vandita Grover – Investigadora en el Departamento de Ciencias de la Computación, Universidad de Delhi y Hema Banati – Profesora del Dyal Singh College, Universidad de Delhi.

### Técnica de recolección:

Las autoras no recolectaron datos desde cero, sino que compilaron y unificaron datos de cinco datasets públicos ya existentes que contienen textos etiquetados como sarcásticos o no sarcásticos. Estos conjuntos de datos provenían principalmente de publicaciones en Twitter y Facebook.

- Ghosh y Veal [2] Tweets etiquetados manualmente como sarcásticos y no sarcásticos.
- **Subramanian** [3] Publicaciones de Twitter y Facebook con emojis, usadas específicamente para estudiar sarcasmo.

- Oprea y MagdyTweets [4] etiquetados directamente por los autores de los mensajes como sarcásticos o no.
- **Ghosh** [5] Dataset del Shared Task sobre sarcasmo (Twitter y Reddit), basado en anotaciones del corpus Reddit.
- Abu Farha [6] Dataset del iSarcasmEval (SemEval 2022), con etiquetas proporcionadas por los autores de los textos y lingüistas.

Después de combinar los cinco datasets, aplicaron una serie de filtros y transformaciones:

- Filtrado de idioma: eliminaron textos que no estaban en inglés.
- Limpieza de texto: eliminaron URLs, menciones, hashtags y otros caracteres irrelevantes.
- Filtrado por emojis: conservaron solo textos que incluían emojis.
- **Unificación de etiquetas**: estandarizaron las etiquetas de sarcasmo (1 = sarcástico, 0 = no sarcástico).
- Derivación de características: como el emoji más frecuente, su posición, número de repeticiones, y análisis de sentimiento tanto para texto como para emojis.

## Conocimiento de SarcOji:

- Lingüística Computacional: Su principal enfoque es el análisis del lenguaje natural (NLP), especialmente para detectar sarcasmo. Se usa conocimiento lingüístico como la incongruencia semántica (ej. textos expositivos con emojis negativos), la sintaxis, y el contexto.
- Inteligencia Artificial y Aprendizaje Automático: Está diseñado para ser usado en el entrenamiento de modelos de machine learning o deep learning para tareas como: Detección automática de sarcasmo o Clasificación de sentimiento. Incluye features, útiles para los algoritmos: puntuación de sentimientos, frecuencia y posición de emojis, etc.

### Conocimiento por variable:

VARIABLE	TIPO DE CONOCIMIENTO	IMPORTANCIA			
Text	Lingüístico	Es la base del análisis.			
		Contiene un mensaje			
		que puede o no ser			
		sarcástico.			
Sarcastic	Supervisión de aprendizaje automático	Etiqueta binaria que permite entrenar modelos supervisados para clasificar sarcasmo.			
Emojis	Comunicación emocional,	Lista de emojis			

	NLP	presentes. Los emojis
	INLP	son indicativos no
		verbales que enriquecen
		el tono del texto.
MaxEmoji	Estadístico	Emoji más frecuente del
		texto. Puede reflejar la
		intención emocional
		dominante del emisor.
MaxEmojiNum	Estadístico	Número de veces que
Occurrence		aparece el MaxEmoji.
		Refleja la intensidad
		emocional o énfasis
		irónico.
MaxEmailDaa	Due sue ético	
MaxEmojiPos	Pragmático	Posición del emoji en el
		texto. Determina si el
		emoji se usa para
		enfatizar, comentar o
		concluir.
TextSWN	Análisis de sentimientos	Puntaje de sentimiento
		del texto según
		SentiWordNet. Útil para
		detectar polaridad
		superficial del mensaje.
TextVader	Análisis emocional	Sentimiento del texto con
TEXTVAUE	Analisis emocional	
		VADER, que considera
		puntuación, emoticones,
		etc.
TextTextBlob	Análisis emocional	Alternativa simple para
		obtener el sentimiento
		general del texto.
EmojiSWN	Análisis de sentimientos	Sentimiento agregado de
		los emojis según SWN
		(demojizados). Permite
		comparar con el tono
		textual.
EmojiVader	Emocional	Puntaje emocional de
oji vadoi		emojis usando VADER.
		Ayuda a evaluar
		1
		congruencia emocional
	<del> </del>	con el texto.
-mou levtRlob	Emoción textual	Otro enfoque para
EmojiTextBlob	Linocion textual	
LINOJITEXIDIOD	Emocion textual	puntuar el sentimiento
Emoji iextolob	Emodoritextual	puntuar el sentimiento total de los emojis del
Linoji lextblob	Emocion textual	• • • • • • • • • • • • • • • • • • •
MEmojiWN	Lingüística computacional	total de los emojis del
•		total de los emojis del texto.

		relación entre sarcasmo e intensidad emocional.
MEVader	Lingüística computacional	Igual que el anterior, usando VADER. Facilita el cruce entre polaridad del texto y emoji más usado.
МЕТВ	Emoción	Puntaje de MaxEmoji con TextBlob. Da perspectiva adicional a la interpretación del emoji dominante.
ESR	Computación afectiva	Valor del sentimiento de MaxEmoji usando Emoji Sentiment Ranking, un recurso especializado en emociones emoji.

# Problema a resolver:

Detectar sarcasmo en redes sociales utilizando el emoji como ayuda.

# 2.2. Descripción

Elemento	Descripción
Nombre del dataset	SarcOji
Publicación	2022
Tamaño del dataset	29,377 filas × 15 columnas
Origen de los datos	Cinco datasets públicos de sarcasmo (Twitter, Facebook, Reddit)
Extension Original	Dataframe Serializado
Idioma de las publicaciones	Inglés
Periodo de tiempo cubierto	No especificado exactamente, pero los datasets fuente cubren aprox. 2015 - 2022

# 2.2.1. A nivel de atributos

Atribut o	Significado y contenido	Relevancia en el análisis de sarcasmo	Tipo de dato	Rango de valores	Unidad	Valores únicos	Tipo de variable
Text	El texto completo del post (tweet o Facebook) que contiene al menos un emoji.	Es la fuente primaria de información : aquí se expresa el sarcasmo a nivel de lenguaje.	String (Unico de)	-	-	29 377	Cualitativa libre
Sarcast ic	Etiqueta: 1 si el texto es sarcástico, 0 si no lo es.	Permite entrenar y evaluar clasificador es supervisado s de detección de sarcasmo.	Entero (0/1)	{0, 1}	_	2	Categórica nominal
Emojis	Lista de todos los emojis presentes en el texto (Unicode).	Captura la riqueza multimodal del mensaje: los emojis matizan el tono y pueden ser indicadores no verbales de sarcasmo.	Lista de strings (Unico de)	_	_	~6 000 (combinac iones)	Cualitativa libre
MaxE moji	El emoji (Unicode) que aparece <b>más veces</b> en ese texto.	Identifica el emoji dominante o "más intenso" —	String (Unico de)	_	_	~85	Cualitativa nominal

		clave para analizar su función irónica o enfática.					
MaxE mojiNu mOccu rrence	Número de veces que aparece el MaxEmoji en el texto (≥ 1).	Mide la intensidad emocional o irónica: la repetición enfatiza la carga sarcástica.	Entero	[1, máx. observa do ≈ 10]	veces	~10	Cuantitativa discreta
MaxE mojiPo s	Posición de la primera aparición del MaxEmoji en el texto: 0=inicio, 1=medio, 2=final.	Analiza la pragmática: si el emoji introduce, acompaña o cierra el mensaje sarcástico.	Entero categó rico	{0, 1, 2}	_	3	Categórica ordinal
TextS WN	Puntuación de sentimiento del <b>texto</b> <b>completo</b> según SentiWordNe t.	Permite evaluar la polaridad "superficial " del texto y compararla con la de los emojis para hallar incongruenc ias.	Float	Normal izado a [-1, 1]	puntaje	~29 000	Cuantitativa continua
TextVa der	Puntuación de sentimiento del <b>texto</b> <b>completo</b> según VADER.	VADER incorpora reglas para mayúsculas, signos de exclamació n y emoticones; útil para redes sociales.	Float	[-1, 1]	puntaje	~29 000	Cuantitativa continua
TextTex tBlob	Puntuación de	Ofrece una perspectiva	Float	[-1, 1]	puntaje	~29 000	Cuantitativa continua

	sentimiento del <b>texto</b> <b>completo</b> según TextBlob.	adicional y más "simplificad a" de la polaridad del texto.					
EmojiS WN	Puntuación agregada de sentimiento de todos los emojis según SentiWordNe t.	Mide la polaridad colectiva de los emojis; junto con TextSWN, revela posibles incongruenc ias.	Float	[-1, 1]	puntaje	~29 000	Cuantitativa continua
EmojiV ader	Puntuación de sentimiento de todos los emojis según VADER.	Versión alternativa para medir la carga afectiva de los emojis.	Float	[-1, 1]	puntaje	~29 000	Cuantitativa continua
EmojiT extBlob	Puntuación de sentimiento de todos los emojis según TextBlob.	Completa el análisis comparativo de polaridades texto vs. emojis.	Float	[-1, 1]	puntaje	~29 000	Cuantitativa continua
MEmoj iWN	Puntuación de sentimiento del MaxEmoji según SentiWordNe t.	Focaliza en el emoji dominante; útil para entender su aporte individual al sarcasmo.	Float	[-1, 1]	puntaje	~85	Cuantitativa continua
MEVad er	Puntuación del MaxEmoji según VADER.	Complemen ta MEmojiWN aportando la visión basada en reglas de VADER.	Float	[-1, 1]	puntaje	~85	Cuantitativa continua

МЕТВ	Puntuación del MaxEmoji según TextBlob.	Añade un tercer punto de vista de sentimiento para el emoji dominante.	Float	[-1, 1]	puntaje	~85	Cuantitativa continua
ESR	Puntuación del MaxEmoji según Emoji Sentiment Ranking.	Recurso especializad o en el sentido emocional de emojis; contrapunto frente a herramienta s basadas en texto.	Float	[-1, 1]	puntaje	~85	Cuantitativa continua

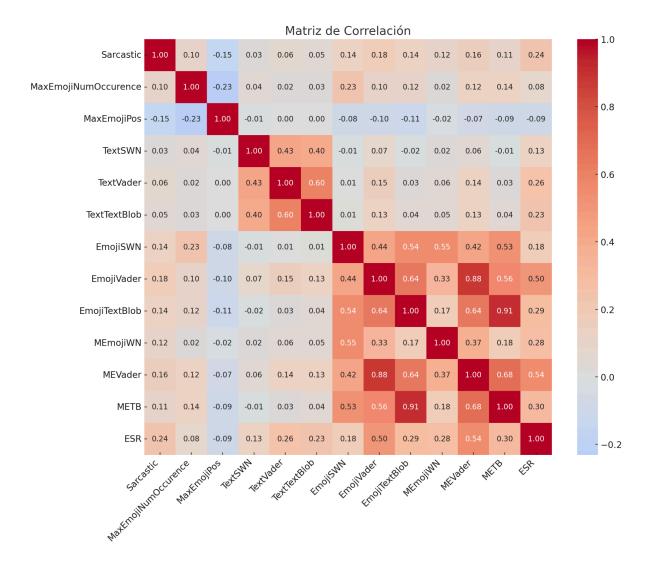
#### 2.2.2. A nivel de registros

Cada registro en el dataset corresponde a un único texto (tweet o publicación de Facebook) que contiene al menos un emoji.

Incluye información textual y emocional del mensaje y sus emojis, así como características calculadas como:

- El emoji más usado (MaxEmoji)Su posición en el texto
- La intensidad de su aparición
- Puntuaciones de sentimiento para texto y emojis
- Está etiquetado con sarcastico o no sarcástico

### 2.2.3. Relación entre atributos



### 2.3. Formato

El conjunto de datos original se encuentra con extensión .df, un archivo serializado de un Pandas DataFrame guardado mediante pickle, es decir, un formato binario que conserva toda la estructura y tipos de datos de un DataFrame en Python.

Característica	Descripción
Tipo de archivo	Binario (no legible directamente como texto)
Extensión	.df
Estructura interna	Tabular, con filas y columnas
Soporte de tipos complejos	Puede guardar listas, strings, enteros, floats, objetos, etc.
Ventaja	Conserva la estructura original del DataFrame (índices, tipos, columnas).
Desventaja	No es portable entre lenguajes (solo útil en entornos Python con pandas).

### 2.4. Transformaciones

El dataset se encuentra en un formato serializado, conserva su estructura original en formato dataframe de pandas, listo para ser utilizable.

# 2.5. Limpieza de datos

### 2.5.1. Valores Faltantes

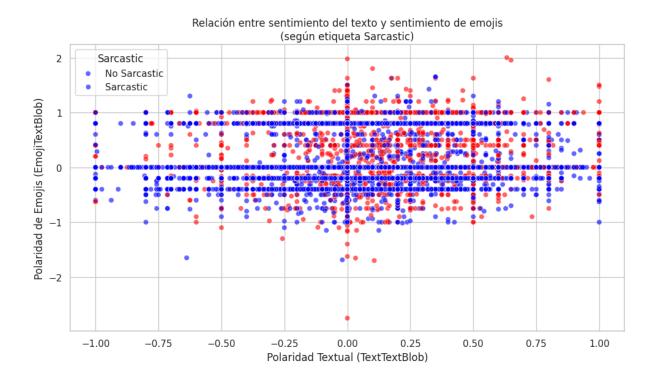
El dataset representa valores nulos (NaN) mediante el número -1, lo que provocó que en un primera revisión no se hallará este detalle. Se siguieron los siguientes pasos para tratar los datos faltantes:

- 1. Detectar qué columnas utilizan -1 para representar valores ausentes. (MaxEmojiNumOccurence y MaxEmojiPos)
- 2. Reemplazo sistemático de -1 por NaN (Las funciones de pandas tratan NaN como "perdido", pero -1 puede ser interpretado erróneamente como un valor válido.)
- 3. Análisis del patrón de valores faltantes

- 4. Tratamiento de los valores nulos
- 5. Eliminar columnas/filas

# 3. Exploración

• ¿Existe una correlación entre el sentimiento del texto y el sentimiento de los emojis? ¿Se debilita o desaparece esa correlación cuando la publicación es sarcástica?



TextBlob del texto: TextTextBlob

• TextBlob de los emojis: EmojiTextBlob

 Sarcastic (0 o 1) como hue para diferenciar los casos sarcásticos y no sarcásticos

### Casos no sarcásticos (azul):

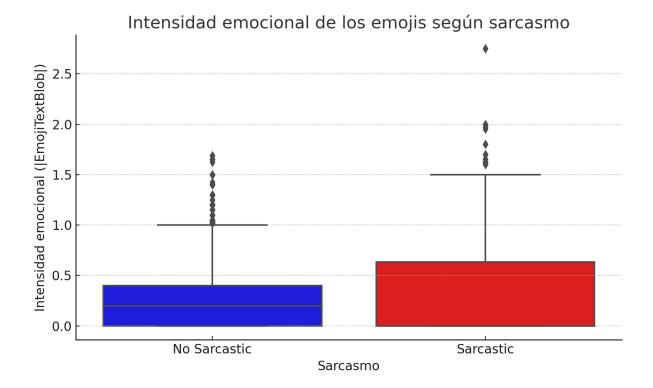
- Tienden a alinearse más a lo largo de una diagonal positiva (de abajo a la izquierda a arriba a la derecha), lo que sugiere que el sentimiento del texto y el de los emojis suelen concordar.
- Esto indica coherencia emocional: si el texto es positivo, los emojis también lo son, y lo mismo con lo negativo.

### Casos sarcásticos (rojo):

- Están más dispersos y menos alineados con la diagonal.
- Se observan puntos donde el texto tiene polaridad positiva pero los emojis tienen polaridad negativa o neutra, y viceversa.
- Esto sugiere una desconexión entre lo que dice el texto y lo que expresan los emojis, lo cual es consistente con el uso del sarcasmo como contradicción emocional o ambigüedad comunicativa.

Este gráfico apoya la hipótesis 1. La distribución dispersa de los puntos rojos indica que los sentimientos expresados en los textos sarcásticos no están alineados con los sentimientos expresados por los emojis, lo que es característico del sarcasmo.

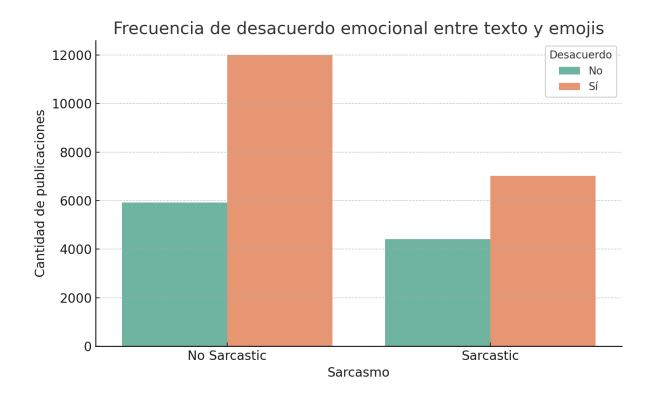
• ¿Las publicaciones sarcásticas utilizan emojis con una mayor intensidad emocional (ya sea positiva o negativa) que las publicaciones no sarcásticas?



El grupo sarcástico (Sarcastic = 1, en rojo) muestra una mediana y una dispersión de intensidad emocional mayor que el grupo no sarcástico (Sarcastic = 0, en azul).

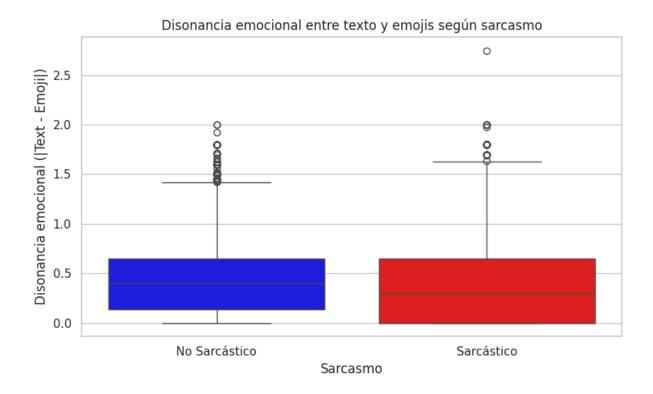
Esto sugiere que las publicaciones sarcásticas tienden a usar emojis con emociones más intensas (tanto positivas como negativas), en línea con la hipótesis 2.

• ¿El sarcasmo es más frecuente en publicaciones que expresan emociones negativas, ya sea en el texto o en los emojis?



- En publicaciones sarcásticas (barra roja a la derecha), hay una mayor proporción de casos con desacuerdo emocional (barra verde claro) en comparación con publicaciones no sarcásticas.
- Esto respalda visualmente la hipótesis 3: el sarcasmo tiende a manifestarse con mayor frecuencia cuando hay una incongruencia entre lo que se dice (texto) y lo que se expresa con emojis.

• ¿Las publicaciones sarcásticas presentan mayor disonancia emocional entre el texto y los emojis, es decir, una menor coherencia entre ambos tipos de sentimiento?



# 4. Conclusión

# 1. Correlación débil entre texto y emojis en publicaciones sarcásticas (Hipótesis 1)

- Los gráficos de dispersión revelaron que los textos sarcásticos presentan una mayor dispersión entre el sentimiento del texto (TextTextBlob) y el sentimiento de los emojis (EmojiTextBlob).
- En cambio, los textos no sarcásticos muestran una correlación más alineada, con mayor coherencia emocional entre palabras y emojis.
- Esto sugiere que el sarcasmo rompe la congruencia emocional entre lenguaje verbal y visual, apoyando la hipótesis de que el sarcasmo es una forma de ambigüedad comunicativa.

## Conclusión intermedia:

- En el grupo no sarcástico, existe una tendencia clara a la alineación: textos con sentimiento positivo presentan emojis positivos y viceversa.
- En el grupo sarcástico, se observa una dispersión mayor y desalineación, con puntos en cuadrantes contradictorios (por ejemplo, texto positivo + emojis negativos).

### Conclusión final:

- La hipótesis se confirma. El sarcasmo debilita o rompe la coherencia emocional entre el lenguaje textual y visual (emojis).
- Esta falta de correlación en textos sarcásticos es un patrón identificable y potencialmente útil para tareas de detección automática de sarcasmo.

# 2. Mayor intensidad emocional en emojis sarcásticos (Hipótesis 2)

- Al analizar la magnitud absoluta de la polaridad de los emojis (|EmojiTextBlob|), se observó que los textos sarcásticos tienden a incluir emojis con emociones más extremas.
- El boxplot evidenció que la mediana y la variabilidad de la intensidad emocional de los emojis son más altas en comentarios sarcásticos.
- Esto respalda la idea de que el sarcasmo no solo altera la coherencia semántica, sino que también se apoya en emociones visuales exageradas o contrastantes.

## Conclusión intermedia:

- El boxplot muestra que los textos sarcásticos presentan una mayor intensidad emocional en los emojis: tienen una mediana más alta y mayor dispersión.
- Se identificaron valores atípicos con emojis extremadamente positivos o negativos en textos sarcásticos.

### Conclusión final:

 La hipótesis se confirma. Las publicaciones sarcásticas tienden a usar emojis con emociones más intensas, lo que puede interpretarse como una herramienta expresiva para acentuar la ironía o el contraste con el texto.

# 5. Anexos

- Colab
- SarcOji-Dataset

# 6. Referencias

- [1] V. B. H. Grover, «Understanding the Sarcastic Nature of Emojis with SarcOji,» *Association for Computational Linguistics*, vol. Proceedings of the Fifth International Workshop on Emoji Understanding and Applications in Social Media, pp. 29-39, 2022.
- [2] G. A. R. F. S. M. Debanjan, «The Role of Conversation Context for Sarcasm Detection in Online Interactions,» *arXiv*, 2017.
- [3] S. V. S. K. L. H. Subramanian Jayashree, «Exploiting Emojis for Sarcasm Detection,» *Springer International Publishing*, vol. 11549, pp. 70-80, 2019.
- [4] W. M. Silviu Oprea, «iSarcasm: A Dataset of Intended Sarcasm,» arXiv, 2020.
- [5] A. V. S. M. Debanjan Ghosh, «A Report on the 2020 Sarcasm Detection Shared Task,» arXiv, 2020.
- [6] I. S. O. S. W. W. M. Abu Farha, «SemEval-2022 Task 6: iSarcasmEval, Intended Sarcasm Detection in English and Arabic,» *Association for Computational Linguistics*, pp. 802-814, 2022.